

Algoritmo evolutivo para otimizar o comportamento de forrageamento em simulador de colônias de formiga com 300.000 agentes

Kenzo Yves Yamashita Nobre¹, Matheus L. O. d. Silva¹, Eduardo do Valle Simões¹

¹Instituto de Ciências de Matemáticas e de Computação – Universidade de São Paulo (USP)
Caixa Postal 668 – 13566-590 – São Carlos - SP - Brasil

kenzonobre@usp.br, simoes@icmc.usp.br

Abstract. *The foraging phenomenon observed in nature resembles several problems in society that boil down to the collection of some resource, such as the rescue of victims in disaster situations. Considering this similarity, this work proposes to explore the use of evolutionary algorithms to optimize the operations of search and collection of resources, and to analyze the emergent swarm intelligence in a complex system of several integrated individuals. To this end, the project focused on ant behavior and used the Hardware-Accelerated-Ant-Colony-Based-Swarm-System ant simulator to develop algorithms that improve the performance of individuals in foraging situations.*

Resumo. *O fenômeno de forrageamento observado na natureza se assemelha a diversos problemas na sociedade que se resumem a coleta de algum recurso, como o resgate de vítimas em áreas de risco. Considerando essa similaridade, este trabalho propõe explorar o uso de algoritmos evolutivos para otimizar as operações de busca e coleta de recursos, além de analisar a inteligência de enxame emergente em um sistema complexo de vários indivíduos integrados. Para isso, o projeto focou no comportamento de formigas e utilizou o simulador de formigueiro Hardware-Accelerated-Ant-Colony-Based-Swarm-System, para desenvolver algoritmos que melhoram o desempenho de indivíduos em situações de forrageamento.*

1. Introdução

Atualmente, há diversos problemas relevantes na sociedade e na natureza que podem ser modelados como desafios de busca e coleta de recursos. Entre essas situações específicas, é possível citar a coleta de materiais em um ambiente inóspito, como a exploração de Marte; o resgate de vítimas em uma área de risco, como o resgate do grupo de meninos presos em uma caverna na Tailândia em 2018; o modelamento do comportamento de espécies que caçam e coletam seus alimentos em variadas circunstâncias, entre outros exemplos *R. Desse modo, observa-se que uma resolução eficiente desse tipo de problema se mostra impactante visto que minimizar o tempo e o esforço gastos nessas operações de busca e coleta, além de maximizar a quantidade de recursos adquiridos podem representar ganhos nas esferas econômica, social e ambiental.

Considerando a similaridade do comportamento de forrageamento das formigas aos problemas de busca e coleta apresentados, o projeto foca na aplicação de algoritmos evolutivos para desenvolver o comportamento destes insetos e consequentemente

proporcionar uma solução eficiente, como em aplicações de Ant Colony Optimization [Dorigo et al., 2006]. Além disso, esta nova modelagem em relação ao problema inicial permite a aplicação do conceito de inteligência de enxame [Reynolds, 1987], dado que as formigas são múltiplos indivíduos com comportamentos singulares e simples, mas que ao interagirem entre si, manifestam um comportamento inteligente, realizando tarefas mais complexas. Tal aplicação apresenta um grande potencial de impacto na sociedade, pois ela cria um sistema descentralizado e auto-organizado que resolve problemas complexos, executando tarefas sem intervenção humana direta. Assim, desenvolver formigueiros com comportamento eficiente possibilita seu uso em aplicações de situações reais como planejamento de rotas para robôs [Diep, 2021]. Como o comportamento desejado do sistema de formigas é resultante da interação entre centenas ou milhares de indivíduos e não pode ser programado diretamente pelo desenvolvedor do software, é muito difícil para um programador humano ajustar os parâmetros de comportamentos simples e reativos dos indivíduos para obter a solução final. Sendo assim, o objetivo deste projeto é propor a utilização de um algoritmo evolutivo para realizar o ajuste automático dos parâmetros dos indivíduos, como velocidade, quantidade de feromônio depositados, alcance e posição das antenas, etc., para otimizar o comportamento esperado do sistema, que é a coleta e transporte de objetos de interesse. Este projeto é uma extensão do [simulador de colônias de formiga desenvolvido por Matheus Luis Oliveira da Silva em *R](#) e do trabalho de conclusão de curso de George Alexandre Gant (2022) chamado “Algoritmo Evolutivo Aplicado a Simulador de Formigueiro” [*R](#). Os autores propõem o desenvolvimento de um algoritmo evolutivo que possa ser acoplado à interface de configuração do simulador para que os parâmetros dos indivíduos possam ser controlados diretamente pelo processo evolutivo e para que a quantidade de objetos coletados e transportados até o ninho possa ser medida e otimizada com o passar das gerações.

2. Simulador de formigueiro

O projeto utilizou o simulador de formigueiro Hardware-Accelerated-Ant-Colony-Based-Swarm-System para observar o comportamento das formigas e poder aplicar as diferentes estratégias e métodos dos algoritmos evolutivos. É possível acessar o código-fonte desse sistema no repositório do [Hardware-Accelerated-Ant-Colony-Based-Swarm-System](#) no Github [*R](#) e seu funcionamento e operação são explicados no relatório [“Implementação de um Sistema de Busca e Resgate Baseado em Inteligência de Grandes Exames Acelerados em Hardware” *R](#).

A escolha deste simulador para realizar os estudos se deu pela sua praticidade, a facilidade de visualização das ações das formigas, além dos comportamentos específicos de forrageamento desses insetos na interface visual do software, que se assemelham aos de formigas reais. Este simulador permite a simulação simultânea e a visualização em 30 frames por segundo dos comportamentos de sensoramento, navegação e coleta de objetos de até meio milhão de agentes (formigas) em tarefas de forrageamento (coleta e transporte de objetos). No simulador, os comportamentos específicos dos agentes seguem as condições da máquina de estados da Figura 1.

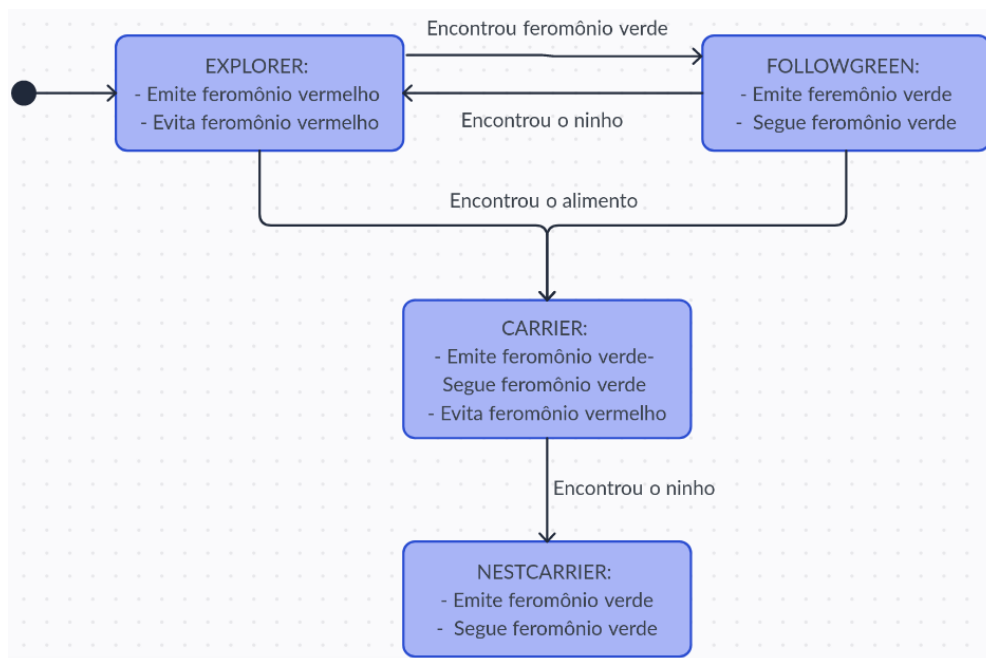


Figura 1. Máquina de estados do comportamento das formigas no simulador

As ações das formigas dentro do simulador se baseiam em dois tipos de feromônio : vermelho e verde. Em suma, o feromônio vermelho serve para indicar que alguma outra formiga que está a procura de alimento passou por determinado lugar, enquanto que o feromônio verde serve para indicar que alguma formiga que já encontrou um alimento passou por determinado lugar. A partir das informações dos feromônios presentes ao redor da formiga e do seu estado atual (seja EXPLORER, FOLLOWGREEN, CARRIER ou NESTCARRIER), o indivíduo decide o que fazer. Dessa maneira, observa-se o evento da estigmergia dentro do simulador, visto que as formigas são agentes que se comportam individualmente seguindo a máquina de estados da Figura 1 e que ao mesmo tempo se comunicam entre si indiretamente pelos feromônios, possibilitando a emergência de uma inteligência coletiva capaz de coletar alimento, da mesma forma que fazem as formigas do mundo real. Este comportamento pode ser visualizado na Figura 2.




Figura 2. Comportamento das formigas com parâmetros base durante uma simulação

3. Algoritmo Genético

Os AGs (Algoritmos Genéticos) são uma área dos algoritmos evolutivos inspirados em biologia evolutiva, a qual é composta por estratégias como seleção natural, recombinação genética, mutação e reconfiguração da população *R. Sua estrutura de funcionamento está demonstrada no diagrama de fluxo da Figura 3.

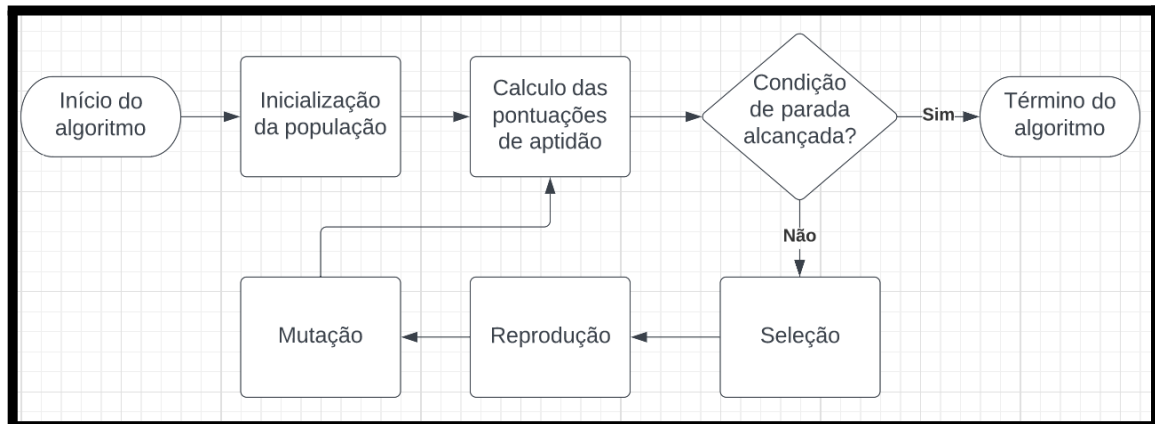


Figura 3. Diagrama de Fluxo de um algoritmo genético convencional

O AG funciona inicializando uma população com muitos indivíduos cujos genes (parâmetros) são variáveis que controlam o comportamento dos agentes (formigas) de um formigueiro. Neste projeto em específico, os indivíduos evoluídos pelo AG são na prática os formigueiros. Então, cada indivíduo (ou cromossomo) de uma geração específica é analisado e recebe uma pontuação denominada *fitness score* (ou pontuação de aptidão), que é um valor que quantifica a aptidão do indivíduo num determinado ambiente. No caso dos experimentos aqui descritos, a aptidão é a quantidade de alimento coletado e transportado para o ninho pelos agentes (formigas) do formigueiro (o indivíduo ou cromossomo que está sendo avaliado pelo AG) após um tempo determinado. Após definir o *fitness score* de cada indivíduo, é feita uma apuração da população por meio de algum método evolutivo que simula a seleção natural. Assim, os melhores indivíduos são escolhidos, se reproduzem (esta etapa também é conhecida como *crossover*) e é inicializado uma nova geração da população com novas configurações de genes. Desta forma, ao continuar esse processo de evolução da população, o algoritmo genético eventualmente encontrará as melhores configurações de genes para o formigueiro desempenhar bem a tarefa de forrageamento para uma dada configuração do ambiente [Mitchell, M. (1998)].

Como procurar por um processo de tentativa-e-erro a configuração perfeita de parâmetros é difícil de ser realizada manualmente pelo programador (considerando que o espaço de busca cresce exponencialmente com o aumento do número de parâmetros controlados pelo AG), escolheu-se aplicar a estratégia do algoritmo genético no simulador de formigueiro para encontrar uma solução eficiente para as operações de busca e coleta de alimentos das formigas. Dentro dessa aplicação, foram utilizados os métodos de elitismo, hereditariedade e mutação variável para otimizar o desempenho do algoritmo *R-minha tese de DOC**.

3.1. Elitismo

Elitismo é um método da fase de seleção e reprodução que consiste em selecionar os indivíduos mais aptos de uma geração e cruzá-los entre si ou com os demais indivíduos para formar a próxima geração. Esta estratégia se caracteriza por convergir rapidamente a solução para ótimos locais, destruindo rapidamente com a diversidade da população e fazendo com que o AG corra o risco de ficar preso nestes ótimos se não for utilizada uma estratégia que possa devolver essa diversidade ao sistema, como por exemplo uma mutação variável. Não obstante, este método de seleção é utilizado no algoritmo genético proposto pois tende a reduzir o número de gerações (avaliações) necessárias para atingir uma boa solução (não necessariamente o ótimo global) em sistemas nos quais o tempo de avaliação é muito grande, que é o caso de simuladores com centenas de milhares de agentes.

3.2. Mutação Variável

Neste trabalho, o termo mutação variável se refere não à quantidade de indivíduos que são escolhidos para mutar, mas sim à grandeza da alteração que é realizada no valor dos seus genes. A cada geração, com a exceção do indivíduo mais apto, todos os indivíduos são escolhidos para realizar o crossover com o mais apto e em seguida sofrem mutação, onde é escolhido um ou mais genes do indivíduo resultante (filho) para serem alterados somando-se ou subtraindo-se um determinado valor. . Como o nome sugere, no método de mutação variável, este valor não é constante e varia de acordo com a situação. Normalmente, esta taxa aumenta quando o algoritmo genético está um tempo considerável sem melhorar a aptidão do melhor indivíduo da população. Isso faz com que a diversidade perdida por métodos de seleção mais agressivos como o elitismo seja devolvida à população, permitindo a busca por uma solução mais distante do ótimo local atingido. Por outro lado, o valor da mutação diminui quando a aptidão do melhor indivíduo está melhorando de uma geração para a outra, pois desse modo os genes dos indivíduos serão alterados de forma mais refinada, permitindo o “ajuste fino” das soluções.

3.3. Hereditariedade - Média da aptidão dos Ancestrais

O método da Hereditariedade pertence à fase do cálculo da pontuação de aptidão de um algoritmo genético e consiste principalmente em não apenas considerar a aptidão de um indivíduo, mas também considerar a aptidão dos seus ancestrais *R-minha tese de DOC**. Este método foi proposto para reduzir a influência de ruído (vários eventos aleatórios que podem ocorrer durante a avaliação do formigueiro, como as diversas interações entre os agentes durante o tempo em que é avaliado). Esse problema acontece em aplicações de AGs a sistemas complexos e dinamicamente mutáveis, nos quais o mesmo indivíduo (contendo a mesma configuração de parâmetros em seu cromossomo) pode receber pontuações diferentes a cada vez que é avaliado, pois as condições do ambiente variam. O problema no caso de AGs é conhecido como “fator sorte”, no qual um mau indivíduo pode obter uma pontuação maior que um bom indivíduo e ser

selecionado em seu lugar para se reproduzir com toda a população, piorando drasticamente a aptidão média da população.

Neste método, é calculada a média da pontuação de aptidão do indivíduo atual e dos seus cinco últimos ancestrais. O indivíduo selecionado para se reproduzir com todos os outros não é aquele com a melhor pontuação na geração atual, mas aquele com a maior média nas últimas seis gerações. Este indivíduo é selecionado para se reproduzir com todos os outros, menos com os que apresentarem pontuação na geração atual maior que a sua. Isso faz com que indivíduos com uma carga hereditária ruim, mas que foram melhorados pelos operadores genéticos da geração atual não sejam modificados pelo processo reprodutivo e tenham mais uma oportunidade de repetir o bom desempenho na próxima geração. Se isso ocorrer, sua média nas últimas seis gerações vai acabar ultrapassando a do melhor de todos (aquele com a maior média nas últimas seis gerações) e ele será então escolhido como o mais apto e irá reproduzir com todos os outros. Caso seja um mau indivíduo que apenas “deu sorte” e obteve um bom desempenho devido à influência de ruído, ele provavelmente não conseguirá repetir o bom desempenho, e irá se reproduzir normalmente.

4. Metodologia e experimentos

4.1. Configuração dos parâmetros constantes

Para validar as comparações entre diferentes experimentos, certos hiperparâmetros foram mantidos como constantes. O tamanho da população do algoritmo genético foi mantido em 10 indivíduos, ou seja, cada geração do algoritmo conta com 10 formigueiros, além de que cada formigueiro possui um número fixo de 1000 formigas. Ademais, a condição de parada ocorre quando um dos dois eventos acontecem : se o algoritmo genético calculou a milésima geração ou se não houve uma melhora no *fitness score* do indivíduo mais apto nas últimas 30 gerações. Finalmente, cada simulação de um formigueiro é calculada através da sua interação com o ambiente, o qual é composto por 4 fontes de alimento (representados pelos quadrados verdes) e o ninho (representado pelo quadrado marrom) demonstrado na Figura 4, durante 15000 frames.




Figura 4. Configuração constante do ambiente de simulação

4.2. Pontuação de aptidão (*Fitness score*)

Neste projeto, a pontuação de aptidão de um formigueiro (denominado de indivíduo no algoritmo genético) é calculada através da quantidade de comida que as formigas trazem para o ninho após uma simulação.

4.3. Parâmetro da Velocidade - Elitismo

A fim validar e avaliar o algoritmo genético desenvolvido, foi escolhido o gene da velocidade para ser o parâmetro variável das formigas. Através desse único parâmetro, foi possível evidenciar o funcionamento do algoritmo e os métodos aplicados sobre ele, pois considerando a forma como a pontuação de aptidão é calculada, pode-se inferir que há uma relação direta entre a velocidade que as formigas se locomovem com a quantidade de comida que elas trazem para o formigueiro. Esta relação não é linear e nem proporcional, mas é uma métrica suficiente para avaliar o desempenho do algoritmo.

O primeiro experimento utilizou-se do seguinte método de elitismo : o indivíduo mais apto da geração é mantido para a próxima geração e ele se reproduz (executa *crossover*) com todos os outros indivíduos de sua geração. Dessa maneira preserva-se a melhor solução encontrada até o momento e melhora a comunidade como um todo. Em contrapartida, este elitismo converge a população para uma configuração de genes muito rapidamente, causando um problema na diversidade e possivelmente, prendendo o algoritmo genético em uma solução ótima local. Por isso, após a fase de seleção e reprodução (observado na Figura 3), vem a fase de mutação dos genes para diversificar a população. Neste primeiro experimento, definiu a taxa de mutação como sendo 5%, ou seja, quando um indivíduo sofre mutação, ele pode variar seu gene em até 5% do espectro do parâmetro da velocidade.

O Gráfico 1 apresenta a evolução da pontuação do melhor indivíduo neste primeiro experimento por meio da linha vermelha, enquanto que o Gráfico 2 apresenta a evolução do parâmetro da velocidade também pela linha vermelha.

4.4. Parâmetro da Velocidade - Elitismo e Hereditariedade

Um problema a ser contornado após a análise do primeiro experimento foi a aleatoriedade do comportamento das formigas. Devido a natureza do funcionamento do simulador, as formigas saem do ninho em linha reta numa configuração radial aleatória no início das simulações, como demonstrado na Figura 5.




Figura 5. Início de uma simulação genérica

Tal aleatoriedade torna o sistema ainda mais complexo de ser analisado, pois além de existir uma interdependência nas interações de cada formiga, a randomicidade no início de cada simulação intensifica o fenômeno do ruído do sistema, o qual nada mais é do que a influência do ambiente e da ação de outros agentes sobre o comportamento de um indivíduo. O problema do ruído em sistemas complexos é que a relação entre a aptidão de um indivíduo não está completamente relacionada com a configuração de seus genes, assim, o algoritmo genético não é perfeitamente certo na comparação entre duas formigas.

Para contornar esse problema, foi aplicado um método específico de hereditariedade sobre o elitismo do primeiro experimento. Ao invés de determinar que o melhor indivíduo é aquele que possui a maior pontuação de aptidão e selecioná-lo para reprodução, determina-se que o melhor indivíduo é aquele cuja média da sua pontuação e dos seus últimos 4 ancestrais é a maior. Desse modo, é considerado o histórico de cada indivíduo e é evitado parcialmente que um formigueiro não muito apto, mas que teve sorte de pontuar alto, seja selecionado para se reproduzir com o resto da população, pois não apenas sua performance atual está sendo analisada como também a performance dos seus antepassados. Além disso, neste experimento, após o melhor indivíduo ser selecionado, ele apenas se reproduz (executa *crossover*) com outros que possuem o *fitness score* menor que o seu, assim, indivíduos que tiveram uma pontuação maior são preservados, pois eles possuem um potencial de melhora, mesmo que o seu histórico de aptidão esteja ruim.

O Gráfico 1 apresenta a evolução da pontuação do melhor indivíduo neste segundo experimento por meio da linha laranja, enquanto que o Gráfico 2 apresenta a evolução do parâmetro da velocidade também pela linha laranja.

4.5. Parâmetro da Velocidade - Elitismo, Hereditariedade e Taxa de Mutação Variável

Para melhorar o algoritmo até então desenvolvido, adicionou-se o método da taxa de mutação variável. Esta estratégia foi implementada da seguinte maneira :

Inicialmente a taxa de mutação é definida como 5%.

Se durante 5 gerações não houve alteração do melhor indivíduo, a taxa sobe para 10%.

Se durante 10 gerações não houve alteração do melhor indivíduo, a taxa sobe para 20%.

Se durante 15 gerações não houve alteração do melhor indivíduo a taxa sobe para 40%. Se durante 20 gerações não houve alteração do melhor indivíduo a taxa sobe para 80%. E por fim, se houver alteração do melhor indivíduo em algum momento, a taxa de mutação volta a ser 5%.

O Gráfico 1 apresenta a evolução da pontuação do melhor indivíduo neste terceiro experimento por meio da linha verde, enquanto que o Gráfico 2 apresenta a evolução do parâmetro da velocidade também pela linha verde.

4.6. Resultados e discussão

A partir dos experimentos, foi possível gerar o gráfico de aptidão por geração (Gráfico 1) e o gráfico de velocidade por geração (Gráfico 2), a fim de comparar os resultados dos métodos aplicados no algoritmo genético.




Gráfico 1. Gráfico da pontuação de aptidão do melhor indivíduo por geração dos três experimentos

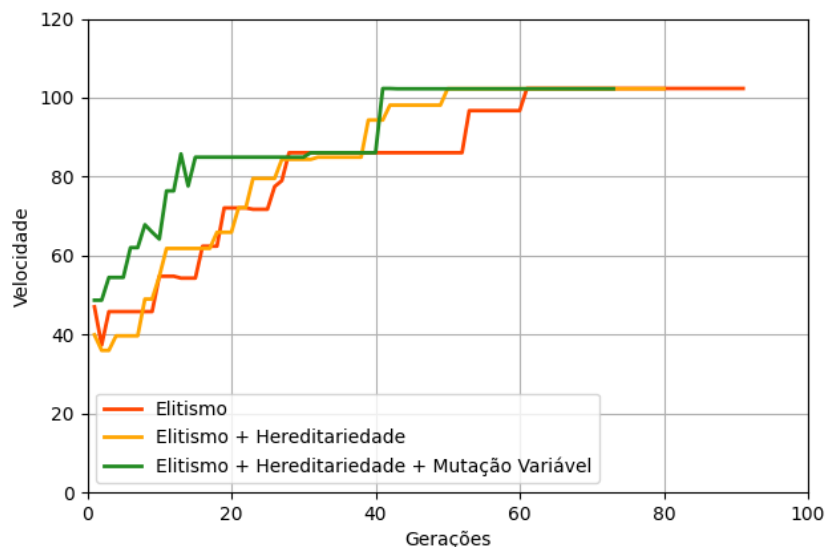


Gráfico 2. Gráfico de velocidade do melhor indivíduo por geração dos três experimentos

Nota-se que o primeiro experimento, o qual utilizou apenas o método do elitismo, demorou mais para encontrar a melhor solução, alcançando-a na geração 61, e portanto teve o pior desempenho. Já o segundo experimento, composto pelo elitismo e hereditariedade, amenizou o fenômeno do ruído do sistema, melhorando o discernimento do algoritmo em relação a comparação da aptidão dos indivíduos e permitindo uma convergência mais rápida da solução, a qual foi alcançada na geração 50. Por fim, foi adicionado o método da taxa de mutação variável no terceiro experimento, desenvolvendo uma adaptação da taxa de mutação e consequentemente da diversidade da população em determinadas situações. Tais mudanças permitiram sutis alterações na configuração dos genes, promovendo uma eficiência na busca pelo melhor indivíduo, o qual foi encontrado na geração 43.

Portanto, os experimentos, juntamente com os gráficos, evidenciam a melhora do algoritmo genético após a adoção dos métodos de elitismo, hereditariedade e taxa de mutação variável, permitindo uma solução eficiente para o problema de forrageamento das formigas no simulador.

5. Conclusão

A partir dos experimentos realizados, foi possível concluir que aplicar um algoritmo genético sobre um sistema complexo de formigueiro que simula as operações de busca e coleta de algum recurso (nesse caso o alimento) é uma forma eficiente de alcançar uma configuração de parâmetros ótima para o problema. Mesmo que o único parâmetro analisado foi o parâmetro da velocidade, pôde-se observar a partir do Gráfico 1 e do

Gráfico 2 que com a aplicação dos métodos evolutivos, houve um aumento de aproximadamente 151% (no último experimento) na coleta de alimentos por parte das formigas (de 57762 para 145201 recursos coletados), além de que a velocidade foi aumentada (no último experimento) em cerca de 110% (de 48.6907 para 102.271 de unidade de velocidade).

O algoritmo genético com os métodos de elitismo, hereditariedade e mutação variável não apenas evoluiu o parâmetro da velocidade das formigas, mas tais estratégias possuem potencial para se estenderem para outros tipos de experimentos com diferentes parâmetros. Portanto, como trabalho futuro, pretende-se explorar a grande gama de parâmetros (como intensidade de feromônio expelido pelas formigas, tamanho dos seus sensores, entre outros) e métodos (como alterar a duração de cada simulação) neste âmbito de algoritmos evolutivos empregados em situações de forrageamento, os quais podem, certamente, ser aplicados em situações reais.

Referências

- Dorigo, M., Birattari, M., & Stutzle, T. (2006). Ant colony optimization. *IEEE Computational Intelligence Magazine*, 1(4), 28–39. <https://doi.org/10.1109/MCI.2006.329691>.
- Reynolds, C. W. (1987). “Flocks, herds and schools: A distributed behavioral model”. *Proceedings of the 14th Annual Conference on Computer Graphics and Interactive Techniques*, 25–34.
- Diep, Q.B., Truong, T.C., Zelinka, I. (2021). Swarm Intelligence and Swarm Robotics in the Path Planning Problem. In: Piunovskiy, A., Zhang, Y. (eds) *Modern Trends in Controlled Stochastic Processes: Emergence, Complexity and Computation*, vol 41. Springer, Cham. https://doi.org/10.1007/978-3-030-76928-4_16
- George Alexandre Gant (2022), “Algoritmo Evolutivo Aplicado a Simulador de Formigueiro”
- Matheus Luis Oliveira da Silva (2022), “Implementação de um Sistema de Busca e Resgate Baseado em Inteligência de Grandes Exames Acelerados em Hardware” <https://github.com/matheuslosilva/Hardware-Accelerated-Ant-Colony-Based-Swarm-System/blob/main/Documentation/PUB1/Relat%C3%B3rio%20Final%20.pdf>.
- Mitchell, M. (1998), “An introduction to genetic algorithms”.